

# MACHINE LEARNING 기계 학습

## 신경망 학습

# PREVIEW

---

## ■ 신경망

- 기계 학습 역사에서 가장 오래된 기계 학습 모델이며, 현재 가장 다양한 형태를 가짐
- 1950년대 퍼셉트론 → 1980년대 다층 퍼셉트론
- 신경망은 딥러닝의 기초가 됨

# 발상과 전개

## ■ 두 줄기 연구의 시너지

- 컴퓨터 과학
  - 계산 능력의 획기적 발전으로 지능 처리에 대한 욕구
- 의학
  - 두뇌의 정보처리 방식 연구 → 얼마간의 성과 (뉴런의 동작 이해 등)

## ■ 뇌의 정보처리 모방하여 인간에 필적하는 지능 컴퓨터에 도전

- 인공 신경망 (ANN; Artificial Neural Network)이 대표적
- 인공 신경망은 생물학적인 신경망에서 영감을 받아서 만들어진 컴퓨팅 구조


# 컴퓨터와 두뇌의 비교

## ■ 폰 노이만 컴퓨터


- 순차 명령어 처리기

## ■ 사람의 뉴런

- 두뇌의 가장 작은 정보처리 단위
- 세포체는 cell body 간단한 연산, 수상돌기는 dendrite 신호 수신, 축삭은 axon 처리 결과를 전송
- 사람은  $10^{11}$ 개 정도의 뉴런을 가지며, 뉴런은 1000개 가량 다른 뉴런과 연결되어 있어  $10^{14}$ 개 정도의 연결



사람의 뉴런의 구조와 동작



(a) 폰 노이만 컴퓨터의 구조

(b) 사람 뇌의 정보 처리 단위인 뉴런

# 전통적인 컴퓨터 vs 인공지능망

	기존의 컴퓨터	인간의 두뇌
처리소자의 개수	$10^8$ 개의 트랜지스터	$10^{10}$ 개의 뉴런
처리소자의 속도	$10^{12}$ Hz	$10^2$ Hz
학습기능	없음	있음
계산 스타일	중앙 집중식, 순차적인 처리	분산 병렬 처리

# 신경망의 간단한 역사

## ■ 간략한 역사

- 1943, McCulloch과 Pitts 최초 신경망 제안
- 1949, Hebb의 학습 알고리즘
- 1958, Rosenblatt 퍼셉트론
- Widrow와 Hoff, Adaline과 Madaline
- 1960대, 신경망의 과대 포장
- 1969, Minsky와 Papert, Perceptrons라는 저서에서 퍼셉트론 한계 지적
  - 퍼셉트론은 선형 분류기에 불과하고 XOR도 해결 못함
  - 이후 신경망 연구 퇴조
- 1986, Rumelhart, Hinton, 그리고 Williams, 다층 퍼셉트론과 오류 역전파 학습 알고리즘
  - 필기 숫자 인식같은 복잡하고 실용적인 문제에 높은 성능
  - 신경망 연구 다시 활기 찾음
  - 현재 가장 널리 활용되는 문제 해결 도구
- 신경망 연구 부활
- 1990년대 SVM에 밀리는 형국
- 2000년대 **딥러닝**이 실현되어 신경망이 기계 학습의 주류 기술로 자리매김

# 수학적 모델로서의 신경망

## ■ 신경망 특성

- 학습 가능 : 데이터만 주어진다면 신경망은 예제로부터 배울 수 있음
- 뛰어난 일반화 능력 : 몇 개의 소자가 오동작하더라도 전체적으로는 큰 문제가 없음
- 병렬 처리 가능
- 현실적 문제에서 우수한 성능
- 다양한 문제 해결 도구 (분류, 예측, 함수 근사화, 합성, 평가, ...)

## ■ 절반의 성공

- 인간 지능에 필적하는 컴퓨터 만들지 못함
- 제한된 환경에서 실용적인 시스템 만드는데 크게 기여 (실용적인 수학적 모델로서 자리매김)

# 퍼셉트론

- 새로운 개념들 등장

- 층
- 노드와 가중치
- 학습
- 활성화 함수


- 비록 분명한 한계를 가지지만 MLP의 초석이 됨



# 뉴런의 구성과 동작원리

## ■ 뉴런의 기본 동작


- 신호를 받아들이고, 이 신호가 축삭 돌기를 지나 축삭 말단으로 전달
- 축삭 돌기를 지나는 동안 신호가 약해지거나, 너무 약해서 축삭 말단까지 전달되지 않거나 혹은 강하게 전달되기도 함
- 축삭 말단까지 전달된 신호는 연결된 다음 뉴런의 가지 돌기로 전달



# 실제 뉴런과 인공 뉴런

## ■ 인공 뉴런의 기본


- 입력신호, 즉 입력값  $x$ 에 가중치( $W$ )를 곱하고 편향( $b$ )을 더한 뒤 활성화 함수(Sigmoid(시그모이드), ReLU(렐루) 등)를 거쳐 결과값  $y$ 를 만들어 냄
- 원하는  $y$ 값을 만들어내기 위해  $W$ 와  $b$ 의 값을 변경해가면서 적절한 값을 찾아냄(이러한 최적화 과정을 학습 또는 훈련)
- $Y = \text{Sigmoid}(x * W + b)$



# 뉴런의 동작원리

## ■ 뉴런의 출력

- 입력 값이 어떤 **분계점(threshold)**에 도달해야 출력 발생
- Ex) 컵에 물을 채울 때 컵을 가득 채워야만 물이 넘친다.




- 입력 신호를 받아 특정 분계점을 넘어서는 경우에 출력 신호를 생성해주는 함수를 활성화 함수라고 함

# 활성화 함수

## ■ 활성화 함수

- 인공신경망을 통과해온 값을 최종적으로 어떤 값으로 만들지를 결정
- 이 함수가 인공 뉴런의 핵심 중에서도 가장 중요한 요소
- 활성화 함수
  - Sigmoid(시그모이드), ReLU(렐루), tanh(쌍곡탄젠트)





# 활성화 함수 예

## ■ 계단 함수(step function)

- 입력 값이 작은 경우 출력 값은 0
- 입력 값이 분계점 이상이면 출력 값은 임의의 값이 출력

## ■ 시그모이드 함수


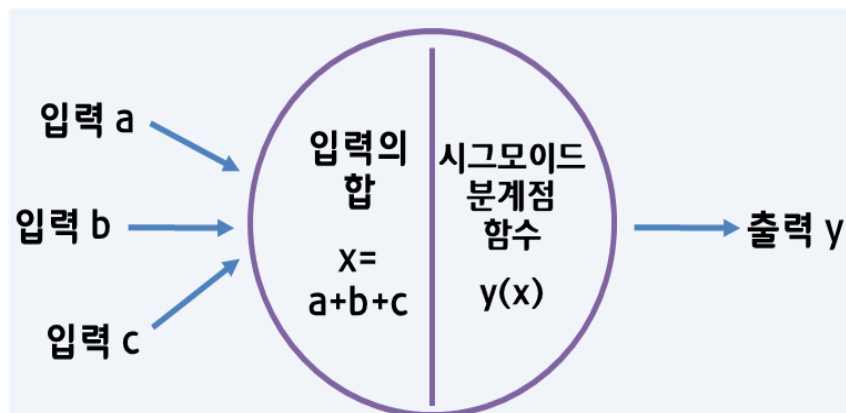
- 로지스틱 함수(logistic function)
- $y = \frac{1}{1+e^{-x}}$
- 예를 들어  $x=0$  일때  $e^{-x} = 1$  이므로  $y = 1/(1+1) = 1/2$




# 뉴런의 동작 과정

## ■ 여러 개의 입력이 있을 경우

- 입력  $a, b, c$ 의 합  $x >$  분계점  $\rightarrow$  시그모이드 함수에서 출력  $X$
- 입력  $a, b, c$ 의 합  $x <$  분계점  $\rightarrow$  시그모이드 함수에서 출력  $O$
- 3개의 입력 값 중 1개의 입력 값만 커도 뉴런 작동 가능




# 뉴런의 수학적 모델



뉴런의 수학적 구조

# 퍼셉트론

- 퍼셉트론(perceptron)은 1957년에 로젠블라트(Frank Rosenblatt)가 고안한 인공 신경망이다.







# 구조와 원리

## ■ 퍼셉트론의 구조

- 입력층과 출력층을 가짐
  - 입력층은 연산을 하지 않으므로 퍼셉트론은 단일 층 구조라고 간주
- 입력층의  $i$ 번째 노드는 특징 벡터  $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$ 의 요소  $x_i$ 를 담당
- 항상 1이 입력되는 바이어스 노드
- 출력층은 한 개의 노드
- $i$ 번째 입력층 노드와 출력층을 연결하는 에지는 가중치  $w_i$ 를 가짐



(a) 퍼셉트론의 구조



(b) 계단함수를 활성화함수  $\tau(s)$ 로 이용함

# 구조와 원리

## ■ 노드의 연산

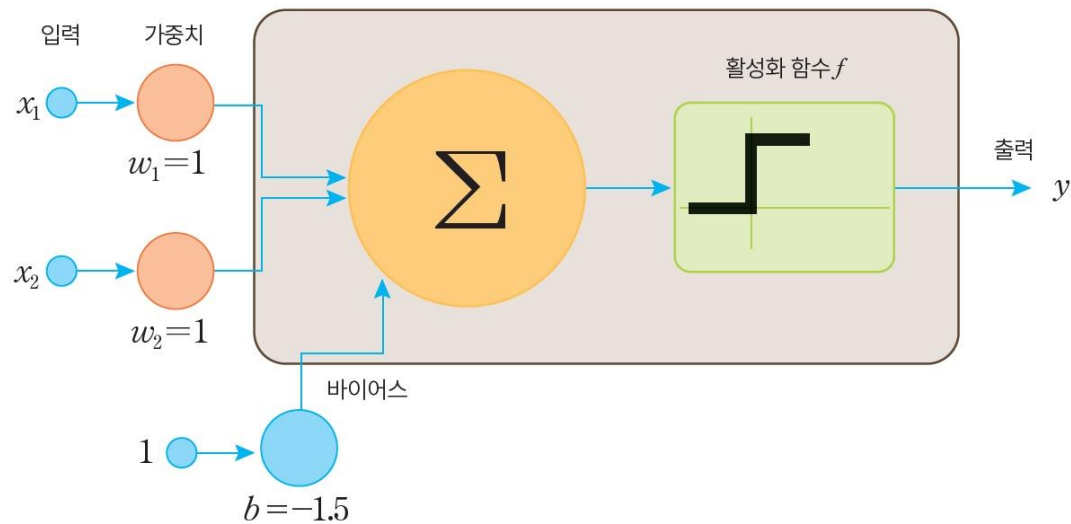
- 입력 노드: 받은 신호를 단순히 전달
- 출력 노드: 합 계산과 활성화 함수 계산

$$\left. \begin{aligned} y = \tau(s) &= \tau\left(\sum_{i=1}^d w_i x_i + b\right) = \tau(\mathbf{w}^T \mathbf{x} + b) \\ \text{이 때 } \tau(s) &= \begin{cases} +1, s \geq 0 \\ -1, s < 0 \end{cases} \end{aligned} \right\}$$

## ■ 퍼셉트론은 선형 분류기

$$\left. \begin{aligned} d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b > 0 \text{ 이면 } \mathbf{x} &\in \omega_1 \\ d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b < 0 \text{ 이면 } \mathbf{x} &\in \omega_2 \end{aligned} \right\}$$

# 퍼셉트론은 논리 연산을 학습할 수 있을까?





논리 연산을 하는 퍼셉트론

x1	x2	y
0	0	0
1	0	0
0	1	0
1	1	1

# 퍼셉트론은 논리 연산을 학습할 수 있을까?

$$\mathbf{a}=(0,0)^T \quad \mathbf{b}=(1,0)^T \quad \mathbf{c}=(0,1)^T \quad \mathbf{d}=(1,1)^T$$





결정 직선 방정식  $d(x) = x_1 + x_2 - 1.5$

퍼셉트론 출력 계산

$x_1$	$x_2$	$w_1x_1+w_2x_2$	$b$	$w_1x_1+w_2x_2+b$	출력
0	0	$1*0+1*0=0$	-1.5	-1.5	0
1	0	$1*1+1*0=1$	-1.5	-0.5	0
0	1	$1*0+1*1=1$	-1.5	-0.5	0
1	1	$1*1+1*1=2$	-1.5	+0.5	1

# 퍼셉트론의 OR 연산 학습

$$\mathbf{a}=(0,0)^T \quad \mathbf{b}=(1,0)^T \quad \mathbf{c}=(0,1)^T \quad \mathbf{d}=(1,1)^T$$



이 퍼셉트론은  $\mathbf{w}=(1,1)^T$ ,  $b=-0.5$ , 활성화 함수는 계단 함수

따라서 결정 직선은  $d(\mathbf{x}) = x_1 + x_2 - 0.5$

# 퍼셉트론 학습 알고리즘

- 학습 세트 :  $m$ 개의 샘플
- $w \cdot x = w_0(t)x_0 + w_1(t)x_1 + \dots + w_n(t)x_n$  벡터의 내적
- $w_i(t)$ 는 시간  $t$ 에서의 가중치  $i$ 의 값

input: 학습 데이터  $(x^1, d^1), \dots, (x^m, d^m)$

① 모든  $w$ 들과 바이어스  $b$ 를  $\theta$  또는 작은 난수로 초기화한다.

② while (가중치가 변경되지 않을 때까지 반복)

③     각 학습 데이터  $x^k$ 와 정답  $d^k$ 에 대하여

④              $y^k(t) = f(w \cdot x)$

⑤             if  $d^k \neq y^k(t)$


⑥                 continue

⑦             else

⑧                 모든 가중치  $w_i$ 에 대하여  $w_i(t+1) = w_i(t) + \eta \cdot (d^k - y^k(t)) \cdot x_i^k$

# 선형 분류 가능 문제



- 패턴 인식 측면에서 보면 퍼셉트론은 직선을 이용하여 입력 패턴을 분류하는 선형 분류자(linear classifier)의 일종이라고 말할 수 있다.



선형 분류자

# 선형 분류 가능 문제

- AND나 OR 연산은 모두 선형 분리 가능한 문제에 속한다



출력    0: ●    1: ●



# XOR 학습 문제

- XOR 연산 : 2개의 입력이 같으면 0, 2개의 입력이 서로 다르면 1이 되는 논리적인 연산
- Minsky와 Papert는 1969년에 발간된 책 "Perceptrons"에서 1개의 레이어 (layer, 계층)으로 구성된 퍼셉트론은 XOR 문제를 학습할 수 없다는 것을 수학적으로 증명
  - 당시에 진행 중이던 모든 신경망 연구가 중단 (신경망의 암흑기)




선형 분리 불가능한 문제

# 다층 퍼셉트론


## ■ 퍼셉트론 2개를 사용한 XOR 문제의 해결

- 퍼셉트론①과 퍼셉트론②가 모두 +1이면 ● 부류이고 그렇지 않으면 □ 부류임



(a) 퍼셉트론 2개를 이용한 공간분할

XOR 문제의 해결




(b) 퍼셉트론 2개

# 다층 퍼셉트론


## ■ 퍼셉트론 2개를 병렬로 결합하면

- 원래 공간  $\mathbf{x} = (x_1, x_2)^T$ 를 새로운 특징 공간  $\mathbf{z} = (z_1, z_2)^T$ 로 변환
- 새로운 특징 공간  $\mathbf{z}$ 에서는 선형 분리 가능함



(a) 두 퍼셉트론을 병렬로 결합

특징 공간의 변환




(b) 원래 특징 공간  $\mathbf{x}$ 를 새로운 특징 공간  $\mathbf{z}$ 로 변환

# 다층 퍼셉트론


## ■ 퍼셉트론 1개를 순차 결합하면,

- 새로운 특징 공간  $z$ 에서 선형 분리를 수행하는 퍼셉트론③을 순차 결합하면, (b)의 다층 퍼셉트론이 됨



(a) 새로운 특징 공간에서 분할

다층 퍼셉트론




(b) 퍼셉트론 3개를 결합한 다층 퍼셉트론

- 이 다층 퍼셉트론은 훈련집합에 있는 4개 샘플  $\begin{pmatrix} 0 \\ 0 \end{pmatrix}$   $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$   $\begin{pmatrix} 1 \\ 0 \end{pmatrix}$   $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 을 제대로 분류하나?

# 다층 퍼셉트론(은닉층)

- XOR 문제는 입력층과 출력층 사이에 은닉층을 두면 쉽게 풀 수 있다



다층 퍼셉트론에서 XOR 문제 해결

$x_1$	$x_2$	$y_1$	$y_2$	$y$	출력
0	0	0	1	0	0
1	0	1	1	1	1
0	1	1	1	1	1
1	1	1	0	0	0

# 다층 퍼셉트론 학습 알고리즘

- Minsky와 Papert는 다층 퍼셉트론을 학습시키는 알고리즘을 찾기가 아주 어려울 것이라고 예언하였다. 예언에 맞았을까? 그렇지 않았다. 1980년대 중반에 Rumelhart와 Hinton 등은 다층 퍼셉트론을 위한 학습 알고리즘을 재발견하게 된다.

